



HƯỚNG DẪN HỌC SPARK CỰC KỲ DỄ HIỂU

Lộ trình 4 bước làm quen với Apache Spark dành cho người mới bắt đầu



Bạn nhỏ ơi! Hãy tưởng tượng Spark giống như một **"Người Bạn Siêu Khổng Lồ"** cực kỳ khỏe mạnh. Bạn ấy có thể giúp chúng mình dọn dẹp hàng triệu món đồ chơi (dữ liệu) trong chớp mắt mà không hề thấy mệt!

BƯỚC 1



Nhặt Đồ Chơi Vào Rổ (Đọc và Lọc Dữ Liệu)



Tưởng tượng đơn giản:

Giống như việc bạn đi chọn những viên lego màu đỏ ra khỏi một đống đồ chơi to đùng vậy đó!

- **Spark làm gì:** Nhặt và lọc đúng những thông tin bạn cần từ đống dữ liệu khổng lồ.
- **Tại sao lại thích:** Bình thường mình tự nhặt thì rất lâu mỏi tay, nhưng Spark làm nhanh trong 1 giây!
- **Lệnh quen thuộc:** `read.csv()` (mở hộp đồ chơi) và `filter()` (lọc đồ màu đỏ).

```
# Đọc file dữ liệu và lọc sản phẩm thuộc nhóm "Điện thoại"
df = spark.read.csv("sales_data.csv", header=True)
dien_thoai_df = df.filter(df["DanhMuc"] == "Điện thoại")
```

BƯỚC 2

Nhờ Bạn Mới Tìm Đồ Hộp (Dùng Spark SQL)

Tưởng tượng đơn giản:

Nếu bạn quen nói tiếng Việt để nhờ: "Cho tớ xin những viên lego hình vuông!", bạn có thể dùng ngôn ngữ SQL để nói chuyện với Spark.

- **Spark làm gì:** Biến tập dữ liệu thành một "Bảng ảo", sau đó lắng nghe các câu lệnh SQL ngắn gọn của bạn.
- **Tại sao lại thích:** Không cần học lệnh phức tạp, cứ dùng câu lệnh SQL quen thuộc là Spark hiểu ngay.
- **Lệnh quen thuộc:** `createOrReplaceTempView("ten_bang")` rồi gọi `spark.sql(...)`.

```
# Đặt tên bảng ảo và hỏi Spark bằng SQL
df.createOrReplaceTempView("do_choi")
ket_qua = spark.sql("SELECT DanhMuc, COUNT(*) FROM do_choi GROUP BY DanhMuc")
```

BƯỚC 3

Cất Đồ Chơi Vào Hộp Dán Nhãn (File Parquet & Partitioning)

Tưởng tượng đơn giản:

Thay vì vứt tất cả đồ chơi lộn xộn trên sàn nhà (file CSV), mình sẽ cất chúng vào các hộp có dán nhãn ngày/tháng rõ ràng.

- **Spark làm gì:** Nén dữ liệu thật nhỏ lại (dạng Parquet) và chia ra các thư mục riêng (Partition).
- **Tại sao lại thích:** Lần sau muốn tìm đồ chơi ngày nào, bạn chỉ cần mở đúng cái hộp ngày đó ra xem, siêu tiết kiệm thời gian!
- **Lệnh quen thuộc:** `df.write.partitionBy("Ngày").parquet(...)`.

```
# Lưu dữ liệu gọn gàng theo từng Thành Phố
df.write.partitionBy("ThanhPho").parquet("kho_do_choi.parquet")
```

BƯỚC 4



Chờ Hồ Biến Mới Làm (Cơ Chế Lazy Evaluation)



Tưởng tượng đơn giản:

Bạn cứ thoải mái bảo: "*Lát nữa tớ muốn nhật màu đỏ, rồi bỏ vào rổ, rồi mang ra cửa nhé*". Bạn Spark sẽ gạt đầu ghi nhớ chứ **chưa vội làm ngay!**

- **Spark làm gì:** Chờ bạn nói hết tất cả các bước để tính toán đường đi ngắn nhất và tiết kiệm sức nhất.
- **Khi nào Spark làm:** Chỉ khi bạn hô to: "*Xong rồi, cho tớ xem kết quả!*" (như lệnh `show()`, `count()`, `write()`), Spark mới chạy một lèo xong luôn!

```
# Spark chỉ ghi chép kế hoạch...
df_loc = df.filter(df["DonGia"] > 100)

# Đến dòng này Spark mới thực sự làm!
df_loc.show()
```

✨ Chúc bạn có những giờ phút học Spark thật vui vẻ và thành công! ✨